## Moonshot Kimi

! [image-20250721153122225] (C:/Users/LENOVO/AppData/Roaming/Typora/typora-user-images/image-20250721153122225.png

## deepseek

```
D:\Work\PipEnvironment\langchainenv\Scripts\python.exe D:\project\LoRATest\Main.py
API模型输出: 90

职位描述: 4年机器学习经验. 熟悉PyTorch和TensorFlow. 做过CV项目 简历内容: 4年机器学习经验. 熟悉PyTorch和TensorFlow 预测匹配分数: 90

预测匹配分数: 贝配

开始评估模型...
API模型输出: 30
API模型输出: 50
API模型输出: 35
API模型输出: 95
API模型输出: 95
```

前期可以通过API快速验证

API调用:优先qwen3,Kimi deepseek太慢了api(4到5秒),国外模型的不稳定需要翻墙

模块	评价
1. 简历解析器	用 Qwen1.5-7B 负责结构化字段提取非常合适, Qwen 对中文理解和文本结构处理都很强,基础数据抽取稳定可靠。
2. 术语标准化/ 改写	用 DeepSeek R7B 模型参数多,生成质量和专业度更高,特别适合精准 改写和术语升级。资源允许的情况下推荐。
3. <b>JD</b> -简历语义 匹配评分	Qwen1.5-7B 作为主模型做匹配和评分很合适,支持 LoRA 微调,且理解能力出色,能做细粒度匹配和缺项提示。
4. 智能简历生 成器	用 Qwen1.5-7B 生成简历符合其强大的文本生成和上下文理解优势,任 务综合度高,表现更稳定。

模型	参数量	4BIT推理显存	LORA增量	微调总显存
Qwen1.5-7B	7B	≈ 5~6 GB	$\approx 1{\sim}2~GB$	$\approx 10\text{~-}12~GB$
DeepSeek R1-7B	7B	≈ 5~6 GB	$\approx 12~GB$	$\approx 10\text{~}12~GB$
<b>★</b> 总共(理想估算)				$\approx 20  24 \text{ GB}$
👉 总共 (实际峰值)	$\approx$ 26~30 GB			